Preparación Certamen 02 - Pauta

Probabilidades y Estadística

Un equipo de Ingeniería Informática compara dos algoritmos de compresión. Cada algoritmo se aplicó a seis archivos diferentes, seleccionados de un repositorio de archivos de características semejantes. Se registró la reducción porcentual del tamaño original: un valor mayor representa una mayor reducción.

Algoritmo	**Reducción del tamaño (%)**					
LZ4	41,73	38,26	45,91	40,68	43,12	39,57
Zstandard	55,84	48,63	52,17	50,92	57,31	53,46

En relación con la situación expuesta, responda las siguientes preguntas seleccionando la alternativa correcta. (5 pts. c/u)

1. ¿Cómo se clasifican las variables estudiadas?
   A. Ambas son cualitativas nominales.
   B. El algoritmo es cualitativo nominal y la reducción es cuantitativa continua.
   C. El algoritmo es cualitativo ordinal y la reducción es cuantitativa discreta.
   D. Ambas son cuantitativas continuas.
2. ¿Cuál es la reducción promedio correspondiente a LZ4?
   A. 40,68 %.
   B. 41,21 %.
   C. 43,12 %.
   D. 41,55 %.
3. ¿Cuál es la mediana de la reducción correspondiente a Zstandard?
   A. 52,82 %.
   B. 53,06 %.
   C. 52,17 %.
   D. 51,55 %.

4. ¿En cuántos puntos porcentuales supera el promedio de Zstandard al promedio de LZ4?

    A. 27,71 puntos porcentuales.

    B. 53,06 puntos porcentuales.

    C. 11,51 puntos porcentuales.

    D. 8,93 puntos porcentuales.

5. ¿Qué representación permite comparar directamente la distribución de la reducción porcentual entre ambos algoritmos?

    A. Un gráfico circular con los doce porcentajes.

    B. Dos diagramas de caja y bigotes sobre una misma escala.

    C. Un gráfico de dispersión asignando arbitrariamente 1 a LZ4 y 2 a Zstandard, para interpretar la pendiente como efecto del algoritmo.

    D. Un gráfico de barras con la cantidad de archivos, sin incorporar sus reducciones porcentuales.

6. Un equipo estudia 18 sectores urbanos de superficie semejante, expuestos a un mismo evento de lluvia. Para cada sector se registraron en 5 puntos distintos el porcentaje de superficie impermeable y el promedio del volumen de escorrentía superficial por hectárea. (véase Tabla 1)

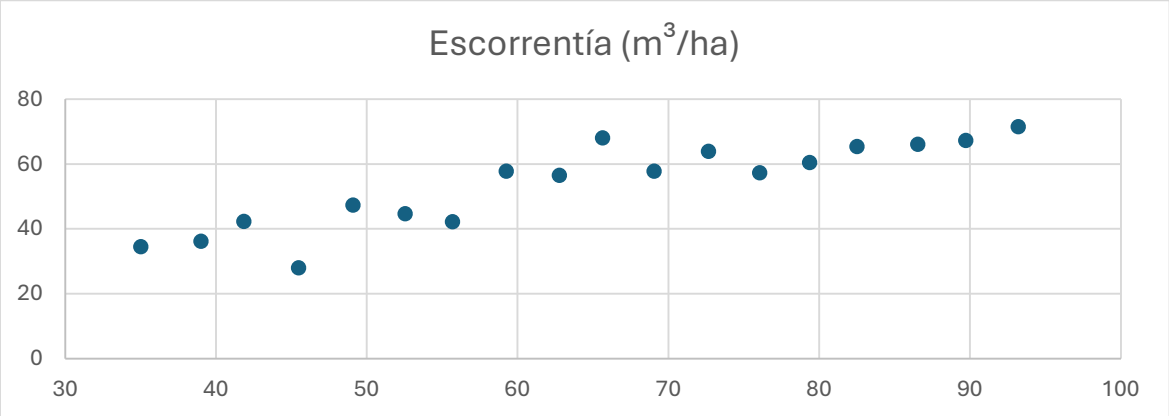
a) Identifica las variables explicativa y respuesta además de la unidad experimental.

X: Porcentaje de superficie impermeable

Y: Promedio del volumen de escorrentía superficial

UE: 5 puntos de cada sector urbano

b) Construye el gráfico de dispersión.



c) Calcula la covarianza muestral e interpreta su signo.

$$Cov(X,Y) = \frac{\sum xy - \frac{\sum x \cdot \sum y}{n}}{n-1} = \frac{65709.4077 - \frac{1155.43 \cdot 967}{18}}{18-1}$$

$$= \frac{65709.4077 - 62072.2672}{17} = 213.9495$$

Al ser la covarianza positiva se tiene que a medida que aumenta el porcentaje de superficie impermeable, la escorrentía aumenta.

d) Calcula e interpreta el coeficiente de correlación de Pearson.

$$R_{XY} = \frac{Cov(X,Y)}{s_x \cdot s_y} = \frac{213.9495}{18.1415 \cdot 13.1028} = \frac{213.9495}{237.7049} \approx 0.9$$

La correlación es positiva fuerte por lo que además las variables porcentaje de superficie impermeable y escorrentía se relacionan linealmente

e) Evalúa la afirmación: «Una correlación alta garantiza que todos los sectores con igual porcentaje de superficie impermeable tendrán la misma escorrentía».

La correlación garantiza la relación entre las variables, por lo que permite el cálculo de estimaciones de respuestas ante cierta variable predictiva, esto no implica que los resultados siempre serán los mismos.

7. Un equipo evalúa distintas configuraciones de un servidor que ejecuta una carga de trabajo comparable. Se registra la memoria asignada a la caché y el porcentaje de solicitudes que requieren acceder al almacenamiento secundario. (véase Tabla 2)

a) Calcula el coeficiente de correlación y determina el modelo de regresión lineal simple.

$$R_{XY} \approx -0.8$$

$$\hat{y} = a + bx$$

$$a = 81.0232$$

$$b = -3.8014$$

Luego el MRLS:

$$\hat{y} = 81.0232 - 3.8014x$$

b) Interpreta la pendiente, indicando las unidades correspondientes.

La pendiente $b = -3.8014$ indica que por cada GB de memoria caché asignada el porcentaje de solicitudes disminuye en un 3,8014%

c) Estima el porcentaje de solicitudes que requieren acceder al almacenamiento cuando se asignan 10,73 GB a la caché.

$$\hat{y} = 81.0232 - 3.8014 \cdot 10.73 \approx 40.23$$

El porcentaje de solicitudes que requieren acceso sería de aproximadamente el 40,23%

d) Según el modelo, ¿cuánta memoria debe asignarse para obtener un porcentaje estimado de 35,62 %?

$$35.62 = 81.0232 - 3.8014x$$

$$\frac{35.62 - 81.0232}{-3.8014} = x \approx 11.94$$

Para el porcentaje estimado de 35,62%, se debe asignar una memoria de 11.94 GB

8. Una planta de tratamiento de aguas de proceso estudia la relación entre la dosificación de floculante y la turbidez del agua después del tratamiento. Una dosis insuficiente puede dificultar la separación de partículas, mientras que una dosificación excesiva puede reducir la eficacia del proceso. Las condiciones del agua también varían entre ensayos. (véase Tabla 3)

a) Divide la muestra entre conjunto de entrenamiento (60%) y prueba (40%).

Ensayo	Dosificación (mg/L)	Turbidez (NTU)	Ensayo	Dosificación (mg/L)	Turbidez (NTU)
1	17.51	131.66	14	22.86	138.26
2	12.37	136.11	15	25.81	152.11
3	14.99	120.34	16	13.94	156.47
4	8.58	136.91	17	6.16	159.26
5	4.83	169.62	18	9.96	156.92
6	7.23	155.33	19	3.31	174.19
7	11.24	130.81	20	24.42	163.49
8	21.76	119.86	21	19.18	145.16
9	20.14	144.21	22	33.16	258.28
10	16.41	132.16	23	34.59	202.42
11	26.87	169.83	24	27.96	150.68
12	31.96	214.18	25	30.56	176.76
13	29.33	192.14			

Entrenamiento / Prueba

b) Con los datos de entrenamiento, calcula la correlación de Pearson y determina el modelo lineal.

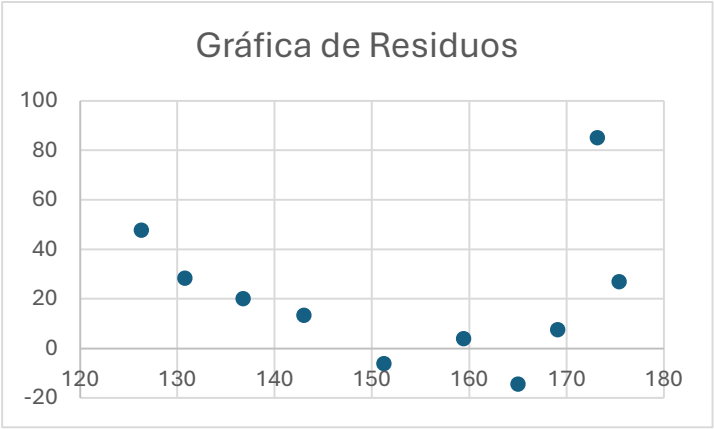
$$R_{XY} = 0.4881$$

$$\hat{y} = 121{,}1263 + 1.5691x$$

c) Construye una tabla con el valor observado, la predicción y el residuo de cada ensayo de prueba.

Ensayo	Dosificación (mg/L)	Turbidez (NTU)	Predicción	Residuo
16	13.94	156.47	143	13.47
17	6.16	159.26	130.79	28.47
18	9.96	156.92	136.76	20.16
19	3.31	174.19	126.32	47.87
20	24.42	163.49	159.44	4.05
21	19.18	145.16	151.22	-6.06
22	33.16	258.28	173.16	85.12
23	34.59	202.42	175.4	27.02
24	27.96	150.68	165	-14.32
25	30.56	176.76	169.08	7.68

d) Construye el gráfico de residuos de prueba. ¿Los residuos se distribuyen sin un patrón reconocible alrededor de cero? Justifica.



Se observa un patrón cuadrático claro en la gráfica de residuos, por lo que podríamos decir es la misma es sesgada.

e) Evalúa si el modelo lineal es adecuado para orientar la dosificación. Fundamenta considerando conjuntamente la dispersión, la correlación y los residuos.

El modelo no es adecuado para este problema, si bien la correlación es moderada, se puede observar desde la gráfica de residuos el sesgo cuadrático, por lo que para este problema un modelo cuadrático sería más apropiado

Tablas

Tabla 1

Sector	Superficie impermeable (%)	Escorrentía (m³/ha)	Sector	Superficie impermeable (%)	Escorrentía (m³/ha)
1	59,24	57,74	10	76,06	57,31
2	49,08	47,33	11	86,54	66,06
3	55,68	42,19	12	79,37	60,47
4	41,86	42,33	13	93,21	71,47
5	39,01	36,17	14	89,72	67,24
6	45,47	27,99	15	82,51	65,37
7	35,02	34,46	16	69,06	57,83
8	62,77	56,49	17	72,66	63,87
9	52,54	44,67	18	65,63	68,01

Tabla 2

Configuración	Memoria de caché (GB)	Solicitudes con acceso al almacenamiento (%)	Configuración	Memoria de caché (GB)	Solicitudes con acceso al almacenamiento (%)
1	8,42	44,61	10	11,31	46,92
2	6,46	45,07	11	13,16	26,16
3	7,81	47,83	12	11,72	33,94
4	5,21	60,06	13	13,92	41,12
5	5,16	63,87	14	13,81	23,67
6	6,26	75,11	15	12,19	39,99
7	4,37	65,56	16	10,01	24,84
8	9,09	45,51	17	10,41	48,18
9	6,87	60,44	18	9,73	34,86

Tabla 3

Ensayo	Dosificación (mg/L)	Turbidez (NTU)	Ensayo	Dosificación (mg/L)	Turbidez (NTU)
1	17,51	131,66	14	22,86	138,26
2	12,37	136,11	15	25,81	152,11
3	14,99	120,34	16	13,94	156,47
4	8,58	136,91	17	6,16	159,26
5	4,83	169,62	18	9,96	156,92
6	7,23	155,33	19	3,31	174,19
7	11,24	130,81	20	24,42	163,49
8	21,76	119,86	21	19,18	145,16
9	20,14	144,21	22	33,16	258,28
10	16,41	132,16	23	34,59	202,42
11	26,87	169,83	24	27,96	150,68
12	31,96	214,18	25	30,56	176,76
13	29,33	192,14			

Formulario

Covarianza Muestral:

$$Cov(X,Y) = \frac{\sum xy - \frac{\sum x \cdot \sum y}{n}}{n-1}$$

Correlación Lineal:

$$R_{XY} = \frac{Cov(X,Y)}{s_x \cdot s_y}$$

Modelo de Regresión Lineal Simple:

$$\hat{y} = a + b \cdot x$$

$$b = \frac{Cov(X,Y)}{s_x^2} \qquad a = \bar{y} - b\bar{x}$$

Coeficiente de variación:

$$CV = \frac{\overline{X}}{s}$$

Residuos:

$$\varepsilon = y - \hat{y}$$