UVM

UNIVERSIDAD VIÑA DEL MAR

Análisis del Error

Modelo de Regresión Simple y Error

En el análisis de datos y la creación de modelos predictivos, la regresión lineal simple es una herramienta fundamental. Su objetivo principal es establecer una relación lineal entre una variable dependiente y una variable independiente, permitiendo así hacer predicciones sobre nuevos datos. Sin embargo, la mera construcción de un modelo de regresión no garantiza su efectividad o precisión. Aquí es donde entra en juego el análisis de los errores del modelo.

$$\hat{y} = a + bx + E$$

Residuos:

$$\varepsilon = y - \hat{y}$$

División de Datos: Conjuntos de Entrenamiento y Prueba

Dividir el conjunto de datos en entrenamiento y prueba es una práctica esencial para desarrollar modelos predictivos efectivos y fiables. Permite evaluar imparcialmente el desempeño del modelo.

- El conjunto de entrenamiento es una porción del conjunto de datos original que se utiliza para ajustar (entrenar) el modelo. Contiene la mayoría de los datos disponibles y se emplea para aprender la relación subyacente entre las variables independientes (características) y la variable dependiente (objetivo).
- El conjunto de prueba es una porción del conjunto de datos original que se reserva y no se utiliza durante el proceso de entrenamiento del modelo. Este conjunto se emplea exclusivamente para evaluar el desempeño del modelo una vez que ha sido entrenado.

Ejemplo de División de Datos
Imaginemos que tenemos un conjunto de datos con 1000 muestras. Dividir estos datos en un 70% para entrenamiento y un 30% para prueba.
•**Conjunto de Entrenamiento:** 700 muestras (utilizadas para ajustar el modelo).
•**Conjunto de Prueba:** 300 muestras (utilizadas para evaluar el modelo).

Gráfica de Residuos

Analizar la gráfica de los residuos en un modelo de regresión lineal (MRL) es fundamental para evaluar la calidad del ajuste del modelo.

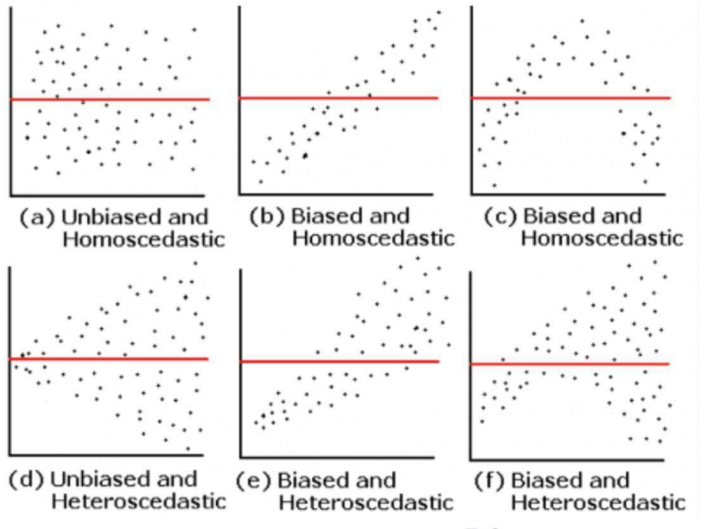
La gráfica de residuos se crea presentando en un eje, los valores predichos $\hat{y}$, y en el otro, los residuos $y - \hat{y}$.
Patrones en la gráfica: Ayuda a identificar si los errores están distribuidos aleatoriamente.

Análisis de la gráfica

- **Patrón Aleatorio**: Si los residuos se distribuyen de manera aleatoria alrededor de la línea horizontal, indica que el modelo es apropiado
- **Patrones No Aleatorios**: Si los residuos muestran un patrón sistemático, como una curva o tendencia, sugiere que el modelo no ha capturado completamente la relación entre las variables.

Gráfica de Residuos

- Sesgo: El sesgo se refiere a la diferencia sistemática entre las predicciones del modelo y los valores verdaderos.
- Homocedasticidad: La homocedasticidad es una condición en la que los residuos del modelo tienen una varianza constante a lo largo de todos los valores de las variables
- Heterocedasticidad: La heterocedasticidad se refiere a una condición en la que la varianza de los residuos no es constante a lo largo de los valores de las variables independientes.



Ejemplo

En una planta industrial se estudia la relación entre la **temperatura de operación de un equipo [°C]** y su **consumo de energía eléctrica por hora de funcionamiento [kWh]**. Para ello, se registraron ambas variables durante 20 ensayos bajo distintas temperaturas de operación.

a. Divida los datos en conjuntos de entrenamiento (60%) y prueba (40%). Utilice un muestreo aleatorio sin reemplazo para formar estos subconjuntos.

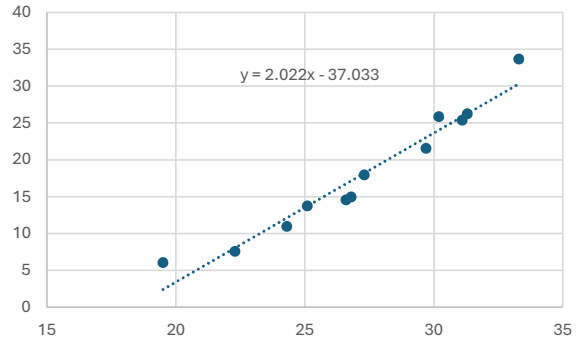
b. Genere el modelo de regresión lineal simple ¿Qué puede concluir respecto del desempeño del modelo?

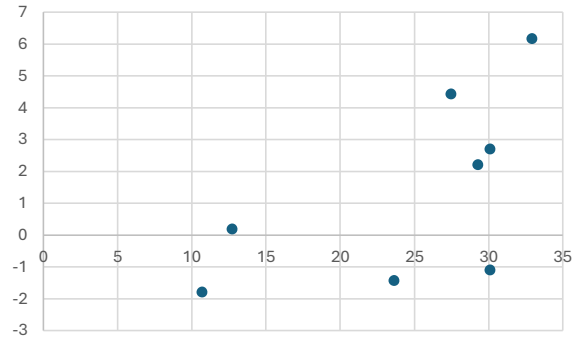
c. Obtenga la gráfica de la recta de regresión y de los residuos para el modelo.

Temperatura operación	Consumo de energía
19.5	6.0
30.2	25.8
27.3	17.9
22.3	7.5
25.1	13.7
33.3	33.6
31.3	26.2
24.3	10.9
31.1	25.3
26.6	14.5
26.8	14.9
29.7	21.5
33.2	32.8
30.0	22.2
34.6	39.1
31.9	31.9
32.8	31.5
23.6	8.9
24.6	12.9
33.2	29.0

Respuesta

Temperatura operación	Consumo de energía	Conjunto
19.5	6	Entrenamiento
30.2	25.8	Entrenamiento
27.3	17.9	Entrenamiento
22.3	7.5	Entrenamiento
25.1	13.7	Entrenamiento
33.3	33.6	Entrenamiento
31.3	26.2	Entrenamiento
24.3	10.9	Entrenamiento
31.1	25.3	Entrenamiento
26.6	14.5	Entrenamiento
26.8	14.9	Entrenamiento
29.7	21.5	Entrenamiento
33.2	32.8	Prueba
30	22.2	Prueba
34.6	39.1	Prueba
31.9	31.9	Prueba
32.8	31.5	Prueba
23.6	8.9	Prueba
24.6	12.9	Prueba
33.2	29	Prueba





Ejercicio

Una empresa industrial utiliza biomasa como combustible para abastecer sus calderas. Para evaluar su calidad energética, se seleccionaron 25 muestras y se midieron su **contenido de humedad [%]** y su **poder calorífico [MJ/kg]**. Se busca predecir el poder calorífico a partir de la humedad para apoyar la selección del combustible.

a. Divida los datos en conjuntos de entrenamiento (60%) y prueba (40%).

b. Genere un modelo de regresión lineal simple utilizando exclusivamente el conjunto de entrenamiento. Interprete la pendiente en el contexto del problema.

c. Obtenga las predicciones para el conjunto de prueba. ¿Qué puede concluir respecto del desempeño predictivo del modelo?

d. Construya el gráfico de dispersión e incorpore la recta del modelo, distinguiendo los datos de entrenamiento y prueba.

e. Grafique los residuos del conjunto de entrenamiento frente a los valores predichos e incluya una línea horizontal en cero. ¿Se distribuyen sin un patrón sistemático? Justifique.

Humedad [%]	Poder calorífico [MJ/kg]	Humedad [%]	Poder calorífico [MJ/kg]
13,5	15,62	15,5	14,91
6,5	20,19	7,5	19,52
16,0	14,79	11,5	17,27
9,0	18,93	16,5	14,00
5,0	22,55	5,5	22,07
12,0	16,26	14,0	16,64
17,0	14,16	8,5	19,95
8,0	19,89	15,0	14,04
14,5	15,08	7,0	19,95
10,5	19,06	12,5	16,96
6,0	20,38	10,0	17,55
13,0	16,83	11,0	17,28
9,5	18,42		

Ejercicio

Una empresa de transporte realiza 25 ensayos con un vehículo de carga, manteniendo condiciones similares de carga y recorrido. En cada ensayo se registra la velocidad media [km/h] y el consumo de combustible [L/100 km]. Se busca evaluar si un modelo lineal permite predecir el consumo a partir de la velocidad.

a. Divida los datos en conjuntos de entrenamiento (60%) y prueba (40%).
b. Genere un modelo de regresión lineal simple utilizando exclusivamente el conjunto de entrenamiento. Interprete la pendiente en el contexto del problema.
c. Construya el gráfico de dispersión e incorpore la recta del modelo
d. Grafique los residuos del conjunto de entrenamiento frente a la velocidad e incluya una línea horizontal en cero. ¿Se observa algún patrón? Identifique los rangos en que el modelo tiende a sobreestimar o subestimar el consumo.

Velocidad media [km/h]	Consumo de combustible [L/100 km]	Velocidad media [km/h]	Consumo de combustible [L/100 km]
72,5	5,06	82,5	5,81
37,5	6,31	42,5	5,51
85,0	6,35	62,5	4,71
50,0	5,35	87,5	6,21
30,0	7,00	32,5	6,21
65,0	5,25	75,0	5,60
90,0	7,00	47,5	5,06
45,0	5,70	80,0	6,10
77,5	5,46	40,0	5,60
57,5	4,81	67,5	5,01
35,0	6,35	55,0	5,35
70,0	5,45	60,0	5,10
52,5	4,96		